

**ANÁLISIS DE LA INFLUENCIA DE FACTORES SOCIOECONÓMICOS EN LAS
PRUEBAS SABER PRO**

JUAN SEBASTIAN RODRIGUEZ CARREÑO - 20231020107

SEBASTIAN RICARDO ACEVEDO BALDOVINO - 20222020095

CARLOS ANDRES PARDO ANGEL - 20231020041



**UNIVERSIDAD DISTRITAL
FRANCISCO JOSÉ DE CALDAS**

UNIVERSIDAD DISTRITAL FRANCISCO JOSÉ DE CALDAS

PROBABILIDAD Y ESTADÍSTICA

GRUPO 020-84

ALBERTO ACOSTA LOPEZ

Introducción

El siguiente trabajo busca encontrar la relación entre los factores socioeconómicos y el desempeño académico de los estudiantes colombianos en las pruebas Saber Pro. Se busca identificar y cuantificar la influencia de diversas variables socioeconómicas en los resultados obtenidos por los estudiantes en el examen de este año, para ambas pruebas y comparar con los resultados del año pasado. Comprender estas dinámicas puede llevar a una conciencia mayor de enfoque para las políticas públicas, así como un mejor entendimiento de la población y que es lo que más la afecta ([1](#)) (Garcia, 2024).

Para abordar esta problemática, se emplearán metodologías de machine learning, específicamente técnicas de regresión lineal, regresión logística y árboles de decisión. La regresión lineal permitirá modelar la relación entre variables socioeconómicas continuas y el puntaje global en la prueba, mientras que la regresión logística se utilizará para analizar la probabilidad de alcanzar ciertos umbrales de desempeño o la elección de programas académicos específicos en función de estos factores. Finalmente, los árboles de decisión ofrecerán una perspectiva no lineal y permitirán identificar interacciones complejas entre las variables predictoras, así como segmentar a la población estudiantil en función de sus características socioeconómicas y su rendimiento académico. El análisis resultante proporcionará información sobre los determinantes socioeconómicos del éxito en las pruebas Saber Pro, y una vez que se tenga esta información, se podrá comparar con los resultados de años anteriores para saber si el modelo que se planteó es viable ([2](#)) (Paterson, 2024).

El grupo de muestra para este trabajo va a pertenecer a los resultados de todas las universidades de Colombia con un programa de ingeniería, y cuyos estudiantes hayan realizado el examen Saber Pro en los periodos académicos 2023-3, 2023-1, 2022-3 y 2022-1.

Objetivos

Objetivo General:

Analizar la relación entre los factores socioeconómicos y el desempeño académico de los estudiantes colombianos de la facultad de ingeniería de seis universidades específicas en las pruebas Saber Pro, y comparar los hallazgos con los resultados de años anteriores para evaluar la viabilidad del modelo planteado.

Objetivos Específicos:

- Identificar y cuantificar la influencia de variables socioeconómicas específicas (a definir según la disponibilidad de datos) en el puntaje global obtenido por los estudiantes de ingeniería en las pruebas Saber Pro, utilizando modelos de regresión lineal.
- Analizar la probabilidad de los estudiantes de ingeniería de alcanzar umbrales de desempeño académico predefinidos en las pruebas Saber Pro, en función de sus factores socioeconómicos, mediante la aplicación de modelos de regresión logística.
- Segmentar a la población estudiantil de ingeniería de las universidades seleccionadas según sus características socioeconómicas y su rendimiento en las pruebas Saber Pro, utilizando los resultados de los modelos de machine learning implementados.
- Comparar los resultados obtenidos para el año con los resultados de años anteriores en las mismas universidades y facultad de ingeniería, con el fin de identificar cambios en la relación entre los factores socioeconómicos y el desempeño académico, y evaluar la consistencia y viabilidad del modelo propuesto a lo largo del tiempo.

Índice

Introducción	2
Objetivos	3
Marco Conceptual	5
Metodología	7
Parámetros, variables y medidas descriptivas de las variables	15
División de datos en subconjuntos representativos para el entrenamiento	21
Patrones y tendencias en los datos	22
Características más relevantes para el modelo	23
Características que se usarán para entrenar el modelo	24
Resultados	26
Conclusiones	27
Bibliografía	28

Marco Conceptual

Para mayor entendimiento del proceso realizado para el método de predicción es fundamental entender términos relevantes del tema, el procesamiento de los datos, la metodología y la interpretación cruda de los datos para generar una conclusión asertiva. “Los modelos predictivos utilizan datos históricos y técnicas de machine learning para identificar patrones y predecir resultados futuros” [\(3\)](#) [\(4\)](#) (Reuters Institute, 2023; McKinsey & Company, 2022), cabe aclarar que en este documento de investigación se harán uso de estas técnicas de machine learning, junto con modelos de regresión y árboles de decisión para hallar patrones y generalizar una predicción.

La tecnología se encuentra en avance continuo y se ve evidenciado en las nuevas formas de investigación y divulgación científica Según el Ministerio de Telecomunicaciones y de la sociedad de la información [\(5\)](#) (2025) “ El machine learning (ML) se basa en el desarrollo de algoritmos que permiten a las computadoras aprender de los datos sin ser programadas explícitamente . Estos algoritmos identifican patrones y hacen predicciones o toman decisiones basadas en los datos que han aprendido“. El machine learning será una de las herramientas más útiles durante el procedimiento pues hará todo el procesamiento en la búsqueda de patrones.

“La regresión lineal múltiple es un modelo estadístico que examina la relación entre una variable dependiente y dos o más variables independientes. Este modelo permite identificar cómo diferentes factores influyen en un resultado específico.” [\(6\)](#) (Martínez Alba et al., 2025).

Este tipo de modelo es esencial al querer buscar una relación específica entre los factores socioeconómicos de los partícipes a los resultados presentados en la prueba de Estado, siendo este último la variable independiente.

Eso junto a los árboles de decisión que se definen como:

“Un árbol de decisión es una regresión a través de la clasificación para minería de datos y otras aplicaciones, representado con una estructura invertida en forma de árbol, donde la raíz en la parte superior es la entrada y las hojas en la parte inferior son los resultados o decisiones” (7) (Panda & Daya Sagar, 2022)

Y finalmente también junto a la regresión logística definida como:

“La regresión logística es un tipo de modelo lineal generalizado, que pertenece a una familia de modelos en los que se relajan las principales suposiciones lineales. La regresión logística es una herramienta excelente para modelar relaciones con resultados que no se miden en una escala continua” (8) (Starbuck, 2023).

Estos modelos más una trata estadística de los datos harán posible la formulación de un método de predicción funcional en torno al contexto deseado y explicado durante el documento.

El Icfes Saber Pro es la prueba de Estado mencionada anteriormente, en la página oficial de la prueba se define según ICFES (9) (2025) como: “El examen de Estado de la Calidad de la Educación Superior, Saber Pro, es un instrumento de evaluación estandarizada para la medición externa de la calidad de la educación superior que evalúa las competencias de los estudiantes que están próximos a culminar los distintos programas profesionales universitarios.”

Metodología

La metodología empleada en este estudio se estructuró en cinco etapas clave: recolección de datos, preprocesamiento, selección de variables, modelado estadístico y validación de resultados. A continuación, se detalla cada una de estas etapas.

1. Recolección de Datos:

Se utilizaron datos públicos de las pruebas Saber Pro, proporcionados por el Instituto Colombiano para la Evaluación de la Educación (ICFES), correspondientes a estudiantes de la facultad de ingeniería de todas las instituciones educativas que presentaron la prueba, para esto se descargaron los elementos correspondientes a los periodos 2023-3, 2023-1, 2022-3 y 2022-1..

Las variables socioeconómicas consideradas incluyeron: pago matrícula anterior semestre (de donde se paga y cuánto), la educación de sus padres, el propio trabajo, el estrato, si tiene conexión a internet, computador, lavadora, horno microondas, servicio de tv, vehiculo (auto o moto), consola de videojuegos, y las horas que trabaja en la semana.

2. Presentación del algoritmo utilizado, para procesamiento de datos:

I. Importación de Bibliotecas:

```
import pandas as pd
import numpy as np
import os
from openpyxl import Workbook
from openpyxl.utils.dataframe import dataframe_to_rows
from openpyxl.styles import Font, PatternFill, Border, Side
```

- **Propósito:** Cargar herramientas para:
 - Manipulación de datos (pandas, numpy).
 - Generación de Excel con formato (openpyxl).
 - Manejo de rutas de archivos (os).

II. Función Principal (procesar_a_excel)

A. Lectura de Datos

```
def procesar_a_excel(input_file, output_excel):
    try:
        # Leer el archivo con el delimitador correcto (;) o '-' dependiendo si es 20232 0 20231 respectivamente

        #df = pd.read_csv(input_file, sep=';', encoding='utf-8')
        df = pd.read_csv(input_file, sep='-', encoding='utf-8', engine='python')
```

- **Detalle:**
 - Lee archivos CSV con delimitador $\neg$ o ; (evita conflictos con texto).
 - engine='python' asegura compatibilidad.

B. Limpieza de Datos:

```
# Limpieza básica de datos
df = df.apply(lambda x: x.str.strip() if x.dtype == 'object' else x)
df.replace(['', 'NA', 'N/A', 'NaN'], np.nan, inplace=True)
```

- **Acciones:**
 - Elimina espacios en blanco.
 - Estandariza valores faltantes como NaN.

C. Creación de Excel


```
# Crear archivo Excel con openpyxl para mejor control
wb = Workbook()
ws = wb.active
ws.title = "Datos ICFES"
```

- **Salida:**
 - Crea un libro de Excel con hoja "Datos ICFES".

D. Configuración de Estilos para Excel:

```
# Estilos para los encabezados
header_font = Font(bold=True, color="FFFFFF")
header_fill = PatternFill(start_color="2c3e50", end_color="2c3e50", fill_type="solid")
thin_border = Border(left=Side(style='thin'),
                    right=Side(style='thin'),
                    top=Side(style='thin'),
                    bottom=Side(style='thin'))
```

- **Propósito:** Define el formato visual del archivo Excel resultante
- **Detalles:**
 - header_font: Texto en negrita y color blanco para encabezados
 - header_fill: Fondo azul oscuro para la fila de encabezados
 - thin_border: Borde delgado alrededor de todas las celdas

E. Escritura de Datos en Excel

```
# Escribir los datos
for r_idx, row in enumerate(dataframe_to_rows(df, index=False, header=True), 1):
    for c_idx, value in enumerate(row, 1):
        cell = ws.cell(row=r_idx, column=c_idx, value=value)
        if r_idx == 1: # Encabezados
            cell.font = header_font
            cell.fill = header_fill
            cell.border = thin_border
```

- **Funcionamiento:**
 - Convierte el DataFrame fila por fila al formato Excel
 - Aplica los estilos solo a la primera fila (encabezados)

- `enumerate(..., 1)` comienza la numeración desde 1 (formato Excel)

F. Ajuste Automático de Columnas

```
# Ajustar el ancho de las columnas
for column in ws.columns:
    max_length = 0
    column_letter = column[0].column_letter
    for cell in column:
        try:
            if len(str(cell.value)) > max_length:
                max_length = len(str(cell.value))
        except:
            pass
    adjusted_width = (max_length + 2) * 1.2
    ws.column_dimensions[column_letter].width = adjusted_width
```

- **Lógica:**

- Calcula el ancho necesario basado en el contenido más largo de cada columna
- $(\text{max_length} + 2) * 1.2$ proporciona un espacio adicional del 20%

G. Funcionalidades Adicionales

```
# Congelar encabezados
ws.freeze_panes = 'A2'

# Guardar el archivo
os.makedirs(os.path.dirname(output_excel), exist_ok=True)
wb.save(output_excel)

print("\n" + "="*50)
print("PROCESAMIENTO COMPLETADO EXITOSAMENTE")
print(f"Archivo Excel generado en: {output_excel}")
print("="*50 + "\n")
```

- **Mejoras de Usabilidad:**

- Encabezados visibles al desplazarse
- Creación automática de directorios
- Guardado seguro del archivo

III. Manejo de Errores:

```
except Exception as e:
    print("\n" + "="*50)
    print("ERROR EN EL PROCESAMIENTO")
    print(f"Error: {str(e)}")
    print("="*50 + "\n")
    raise
```

- **Control de Calidad:**

- Bloque try-except para capturar cualquier error
- Mensajes claros de error con formato visual
- Re-lanza la excepción para depuración

IV. Función Principal (main):

```
def main():
    input_file = 'tu_data.txt'
    output_excel = '/output/icfes_data.xlsx'

    procesar_a_excel(input_file, output_excel)

if __name__ == "__main__":
    main()
```

- **Buenas Prácticas:**

- Punto único de entrada al programa
- Rutas configurables en un solo lugar
- Ejecución condicional (solo si es script principal)

3. Union de datos

Con el fin de que toda la información se encontrará en un único archivo se realizó otro script en python, de manera más sencilla, cuyo propósito fuera el de unir los diferentes datos basado en las categorías comunes entre cada una de las bases de datos, el script es el siguiente:

```
1 import pandas as pd
2 import os
3
4 def joinFiles(ruta_carpeta, columnas_comunes):
5     todos_los_datos = pd.DataFrame()
6     archivos_excel = [f for f in os.listdir(ruta_carpeta) if f.endswith(('.xls', '.xlsx'))]
7
8     if not archivos_excel:
9         print(f"No se encontraron archivos de Excel en la carpeta: {ruta_carpeta}")
10        return
11
12    print(f"Procesando {len(archivos_excel)} archivo(s) de Excel en '{ruta_carpeta}'...")
13
14    for archivo in archivos_excel:
15        ruta_completa_archivo = os.path.join(ruta_carpeta, archivo)
16        try:
17            df = pd.read_excel(ruta_completa_archivo)
18            df.columns = df.columns.str.lower()
19
20            columnas_comunes_lower = [col.lower() for col in columnas_comunes]
21
22            columnas_a_extraer = [col for col in columnas_comunes_lower if col in df.columns]
23
24            if not columnas_a_extraer:
25                print(f"Advertencia: El archivo '{archivo}' no contiene ninguna de las columnas especificadas. Se ignorará.")
26                continue
27
28            df_seleccionado = df[columnas_a_extraer]
29
30            todos_los_datos = pd.concat([todos_los_datos, df_seleccionado], ignore_index=True)
31            print(f" - '{archivo}' procesado correctamente.")
32
33        except Exception as e:
34            print(f"Error al procesar el archivo '{archivo}': {e}")
35
36    if not todos_los_datos.empty:
37        nombre_salida = "datos_combinados_filtrados.xlsx"
38        ruta_salida = os.path.join(ruta_carpeta, nombre_salida)
39        todos_los_datos.to_excel(ruta_salida, index=False)
40        print(f"\nProceso completado! Los datos combinados y filtrados se guardaron en: {ruta_salida}")
41    else:
42        print("\nNo se pudieron combinar datos de ningún archivo. Revisa los archivos y las columnas especificadas.")
```

Se usaron las librerías pandas y os, pandas se usó para manipular la información de los archivos .xlsx y pasarlos a dataframes con la función .read_excel para posteriormente ser unidos en un único dataframe que a su vez pasaría por la función .to_excel para ser exportado

al directorio seleccionado, os se uso principalmente por mas comodidad, ya que el programa fue hecho para que todos los archivos .xlsx dentro de la carpeta fueran procesados sin tener que especificar su direccion.

```
44 #Columnas que se desean extraer de los archivos Excel
45 columnas_deseadas = [
46     "ESTU_TIPODOCUMENTO", "ESTU_NACIONALIDAD", "ESTU_GENERO", "ESTU_FECHANACIMIENTO",
47     "ESTU_EXTERIOR", "PERIODO", "ESTU_CONSECUTIVO", "ESTU_ESTUDIANTE",
48     "ESTU_PAIS_RESIDE", "ESTU_DEPTO_RESIDE", "ESTU_COD_RESIDE_DEPTO",
49     "ESTU_MCPIO_RESIDE", "ESTU_COD_RESIDE_MCPIO", "ESTU_AREARESIDE",
50     "ESTU_TITULOBTENIDOBACHILLER", "ESTU_VALORMATRICULAUNIVERSIDAD",
51     "ESTU_PAGOMATRICULABECA", "ESTU_PAGOMATRICULACREDITO",
52     "ESTU_PAGOMATRICULAPADRES", "ESTU_PAGOMATRICULAPROPIO",
53     "ESTU_COMOCAPACITOEXAMENSB11", "ESTU_TIPODOCUMENTOSB11",
54     "ESTU_SEMESTRECURSA", "FAMI_EDUCACIONPADRE", "FAMI_EDUCACIONMADRE",
55     "FAMI_OCUPACIONPADRE", "FAMI_OCUPACIONMADRE", "FAMI_ESTRATOVIVIENDA",
56     "FAMI_TIENEINTERNET", "FAMI_TIENECOMPUTADOR", "FAMI_TIENELAVADORA",
57     "FAMI_TIENEHORNOMICROOGAS", "FAMI_TIENESERVICIO", "FAMI_TIENEAUTOMOVIL",
58     "FAMI_TIENEMOTOCICLETA", "FAMI_TIENECONSOLAVIDEOJUEGOS",
59     "FAMI_TRABAJOLABORPADRE", "FAMI_TRABAJOLABORMADRE",
60     "ESTU_HORASSEMANATRAABA", "ESTU_PAGOMATRICULA",
61     "INST_COD_INSTITUCION", "INST_NOMBRE_INSTITUCION",
62     "ESTU_PRGM_ACADEHICO", "ESTU_SNIES_PRGMACADEHICO", "GRUPOREFERENCIA",
63     "ESTU_PRGM_CODMUNICIPIO", "ESTU_PRGM_MUNICIPIO", "ESTU_PRGM_DEPARTAMENTO",
64     "ESTU_NIVEL_PRGM_ACADEHICO", "ESTU_METODO_PRGM", "ESTU_NUCLEO_PREGADO",
65     "ESTU_INST_CODMUNICIPIO", "ESTU_INST_MUNICIPIO", "ESTU_INST_DEPARTAMENTO",
66     "INST_CHARACTER_ACADEHICO", "INST_ORIGEN", "ESTU_PRIVADO_LIBERTAD",
67     "ESTU_COD_MCPIO_PRESENTACION", "ESTU_MCPIO_PRESENTACION",
68     "ESTU_DEPTO_PRESENTACION", "ESTU_COD_DEPTO_PRESENTACION",
69     "MOD_RAZONA_CUANTITAT_PUNT", "MOD_RAZONA_CUANTITAT_DESEM",
70     "MOD_RAZONA_CUANTITATIVO_PNAL", "MOD_RAZONA_CUANTITATIVO_PNBC",
71     "MOD_Lectura_CRITICA_PUNT", "MOD_Lectura_CRITICA_DESEM",
72     "MOD_Lectura_CRITICA_PNAL", "MOD_Lectura_CRITICA_PNBC",
73     "MOD_COMPETEN_CIUADADA_PUNT", "MOD_COMPETEN_CIUADADA_DESEM",
74     "MOD_COMPETEN_CIUADADA_PNAL", "MOD_COMPETEN_CIUADADA_PNBC",
75     "MOD_INGLES_PUNT", "MOD_INGLES_DESEM", "MOD_INGLES_PNAL",
76     "MOD_INGLES_PNBC", "MOD_COMUNI_ESCRITA_PUNT", "MOD_COMUNI_ESCRITA_DESEM",
77     "MOD_COMUNI_ESCRITA_PNAL", "MOD_COMUNI_ESCRITA_PNBC",
78     "PUNT_GLOBAL", "PERCENTIL_GLOBAL", "PERCENTIL_PNBC", "ESTU_ESTADOINVESTIGACION"
79 ]
80
81 if __name__ == "__main__":
82     #Carpeta local
83     carpeta_a_procesar = '.'
84     joinFiles(carpeta_a_procesar, columnas_deseadas)
```

Estos son parámetros extras que se pasaron a la función joinFiles que da funcionamiento al script y que nos permitió juntar los datos completos que en total darían 469380.

4. Filtrado de datos

Una vez se limpio la base de datos y se unieron los datos, se procedió a filtrar la información pertinente con la que se trabajara, se realizó únicamente la comparación de el campo de grupo de referencia filtrando por carreras afines con el área de ingeniería, el script con el que se desarrolló dicho filtrado es el siguiente:

```
main.py > ...
1  import pandas as pd
2
3  file_path = 'icfes_data.xlsx'
4  data = pd.read_excel(file_path)
5
6  grupo = "INGENIERÍA"
7
8  dataFiltered = data[
9      data['gruporeferencia'] == grupo
10 ]
11
12 dataFiltered.to_excel('icfesFiltered.xlsx', index=False)
13
14 print(dataFiltered)
```

Se puede evidenciar el uso de la librería pandas (en conjunto con la librería openPyxl) para la función `read_excel`, y se filtraron los datos con el conjunto de caracteres “INGENIERÍA” dentro de la columna pertinente en la base de datos, una vez que este proceso se realizó, se guardaron los datos en otro excel llamado “SaberProFiltered.xlsx” haciendo uso de la función `to_excel` (con un `index` falso para no generar cabeceras adicionales a los datos), en total se contaría con 90624 datos que servirán como nuestro muestreo en el análisis

Parámetros, variables y medidas descriptivas de las variables

En el procedimiento de la revisión del documento guía para hacer este análisis junto a él excel filtrado de los datos referentes se establecen las siguientes variables, también establecidas por el autor del documento guía (García Cano, 2024):

De las variables seleccionadas podemos mencionar las siguientes:

Características personales:

- Género del estudiante: (ESTU_GENERO)
- Fecha de nacimiento del estudiante: (ESTU_FECHANACIMIENTO)
- Indica si el estudiante pertenece a una etnia: (ESTU_TIENEETNIA).
- Tipo de documento del estudiante: (ESTU_TIPODOCUMENTOSB11).
- Semestre que el estudiante está cursando: (ESTU_SEMESTRECURSA).
- Edad del estudiante: (EDAD_ESTUDIANTE).

Características familiares:

- Nivel de educación del padre: (FAMI_EDUCACIONPADRE).
- Nivel de educación de la madre: (FAMI_EDUCACIONMADRE).
- Estrato socioeconómico de la vivienda del estudiante:
(FAMI ESTRATOVIVIENDA).
- Indica si la familia del estudiante tiene internet: (FAMI_TIENEINTERNET).
- Indica si la familia del estudiante tiene computador:
(FAMI TIENECOMPUTADOR).

Características socioeconómicas/geográficas:

- Departamento de residencia del estudiante: (ESTU_DEPTO_RESIDE).

- Código del departamento de residencia del estudiante:
(ESTU_COD_RESIDE_DEPTO).
- Municipio de residencia del estudiante: (ESTU_MCPIO_RESIDE).
- Código del municipio de residencia del estudiante: (ESTU_COD_RESIDE_MCPIO).
- Área de residencia del estudiante (urbano/rural): (ESTU_AREARESIDE).
- Título de bachiller obtenido por el estudiante :
(ESTU_TITULO OBTENIDO BACHILLER).
- Indica si el estudiante paga la matrícula con una beca:
(ESTU_PAGOMATRICULABECA).
- Indica si el estudiante paga la matrícula con un crédito:
(ESTU_PAGOMATRICULACREDITO).
- Indica si los padres pagan la matrícula del estudiante:
(ESTU_PAGOMATRICULAPADRES).
- Indica si el estudiante paga su propia matrícula:
(ESTU_PAGOMATRICULAPROPIO).
- Horas semanales que trabaja el estudiante: (ESTU_HORAS SEMANA TRABAJA).
- Presentación de la casa del estudiante: (ESTU_PRESENTACION CASA).
- Código de la institución educativa: (INST_COD_INSTITUCION).
- Nombre de la institución educativa: (INST_NOMBRE_INSTITUCION).
- Programa académico del estudiante: (ESTU_PRGM_ACADEMICO).
- Código SNIES del programa académico: (ESTU_SNIES_PRGM ACADEMICO).
- Método del programa académico: (ESTU_METODO_PRGM).
- Origen de la institución (pública/privada): (INST_ORIGEN).

Asimismo, para la elección de los algoritmos que harán posible la predicción de los datos se escogen variables principales que representan una conveniencia de acuerdo

directamente al rendimiento académico de los estudiantes, usando el excel filtrado y librerías de pandas se escogen ciertas columnas para con ellas realizar medidas descriptivas de las siguientes variables numéricas, escogidas nuevamente a escogencia por la guía mencionada (García Cano, 2024):

	Datos no nulos	Promedio	esviacion estand	imo del conjunt	25%	50%	75%	Valor maximo	Moda	Valores nulos
estu_cod_reside_depto	90504	118,5824383	2989,518435	0	11	15	52	99999	11	119
estu_cod_reside_mcpio	90504	29320,67527	25319,37531	6	11001	15299	52001	99999	11001	119
inst_cod_institucion	90623	2319,640676	1434,489099	1101	1213	1818	2811	9930	2102	0
estu_snies_prgramacademico	90623	39259,34641	41831,03763	24	2889	17489	90868	109447	101389	0
mod_razona_cuantitat_punt	90623	162,213842	32,92903164	0	140	164	186	300	169	0
mod_razona_cuantitat_desem	90623	2,575946504	0,854832852	1	2	3	3	4	3	0
mod_razona_cuantitativo_pnal										
	90623	66,21364334	27,49272309	1	47	73	90	100	100	0
mod_razona_cuantitativo_pnbc										
	90623	50,64484733	28,8952206	1	26	51	76	100	83	0
mod_lectura_critica_punt	90623	152,4763581	31,45022041	0	130	154	175	300	150	0
mod_lectura_critica_desem	90623	2,313717268	0,855632627	1	2	2	3	4	3	0
mod_lectura_critica_pnal	90623	53,0842391	28,88168595	1	28	55	78	100	96	0
mod_lectura_critica_pnbc	90623	50,49313088	28,9061439	1	25	51	76	100	1	0
mod_competen_ciudadada_punt	90623	144,485859	34,4851228	0	119	146	170	300	149	0
mod_competen_ciudadada_desem										
	90623	2,139247211	0,891611323	1	1	2	3	4	3	0
mod_competen_ciudadada_pnal	90623	52,90916213	29,03198879	1	28	55	78	100	92	0
mod_competen_ciudadada_pnbc	90623	50,56450349	28,89213136	1	26	51	76	100	96	0
mod_ingles_punt	90616	160,3197559	32,438574	0	140	159	180	300	153	7
mod_ingles_desem	0									90623
mod_ingles_pnal	90616	56,53572217	27,52917388	1	35	59	80	100	100	7
mod_ingles_pnbc	90616	50,47600865	28,89320168	1	25	50	76	100	100	7
mod_comuni_escrita_punt	90623	134,8743476	44,71596166	0	122	143	161	300	0	0
mod_comuni_escrita_desem	84901	2,365460949	0,741806264	1	2	2	3	4	2	5722
mod_comuni_escrita_pnal	90623	47,16065458	30,14836303	1	20	47	73	100	1	0
mod_comuni_escrita_pnbc	90623	47,42475972	30,4356723	1	20	47	74	100	1	0
punt_global	90623	151,0616179	25,46961929	0	134	151	168	269	155	0
percentil_global	90616	57,69062859	28,29433842	1	35	61	83	100	97	7
percentil_nbc	90616	50,65289794	28,88367581	1	26	51	76	100	77	7

Fuente: Elaboración propia.

Para un mayor entendimiento de los datos, y la elección de los mismos (García Cano, 2024), establece una descripción de cada variable elegida así:

Tabla 5.

Elección de las variables numéricas.

Variable numérica	Descripción
PERCENTIL_GLOBAL	Percentil global en que se encuentra el evaluado Rango: 0 - 100
PUNT_GLOBA	Puntaje total obtenido Rango: 0 - 300
PERCENTIL_NBC	Percentil núcleo básico de Conocimiento Rango: 0-100
MOD_COMUNI_ESCRITA_PUNT	Puntaje comunicación escrita Rango:0-300
MOD_INGLES_PUNT	Puntaje inglés Rango:0-300
MOD_COMPETEN_CIUADADA_PUNT	Puntaje competencias ciudadanas Rango:0-300
MOD_LECTURA_CRITICA_PUNT	Puntaje lectura crítica 0 - 300
MOD_RAZONA_CUANTITAT_PUNT	Puntaje razonamiento cuantitativo Rango:0-300

Fuente: Adaptado de Técnicas de Machine Learning para la predicción del rendimiento académico en las pruebas Saber Pro en Colombia (p. 34), por M. A. García Cano, 2024, [Trabajo de especialización, Universidad Nacional Abierta y a Distancia].

Finalmente el autor propone escoger unas variables categóricas que ayudarán a una mejor implementación y clasificación en general de los métodos a usar para el tratamiento de los datos.


ESTU_GENERO	Genero
ESTU_FECHANACIMIENTO	Fecha de nacimiento
ESTU_TIENEETNIA	Etnia
ESTU_DEPTO_RESIDE	Departamento de residencia
ESTU_MCPIO_RESIDE	Municipio de residencia
ESTU_AREARESIDE	Área de residencia
ESTU_TITULOBTENIDOBACHILLER	Título de bachillerato obtenido
ESTU_PAGOMATRICULABECA	Pago de matrícula por beca
ESTU_PAGOMATRICULACREDITO	Pago de la matrícula mediante crédito
ESTU_PAGOMATRICULAPADRES	Pago de la matrícula mediante padres
ESTU_PAGOMATRICULAPROPIO	Pago de la matrícula recursos propios
ESTU_SEMESTRECURSA	Semestre que cursa actualmente el estudiante
FAMI ESTRATOVIVIENDA	Estrato socioeconómico de su vivienda según el recibo de energía eléctrica
FAMI_TIENEINTERNET	Su hogar cuenta con conexión a internet
FAMI_TIENECOMPUTADOR	Su hogar cuenta con computador
ESTU_HORASSEMANATRABAJA	Cuántas horas trabaja a la semana

ESTU_PRESENTACIONCASA	Presento la prueba en casa
INST_NOMBRE_INSTITUCION	Nombre de la institución
ESTU_PRGM_ACADEMICO	Nombre del programa académico que cursa
ESTU_METODO_PRGM	Método del programa académico
ESTU_INST_MUNICIPIO	Municipio de la institución
ESTU_INST_DEPARTAMENTO	Departamento de la institución
INST_ORIGEN	Naturaleza u origen de la IES
MOD_INGLES_DESEM	Nivel de ingles


Fuente: Adaptado de Técnicas de Machine Learning para la predicción del rendimiento académico en las pruebas Saber Pro en Colombia (p. 34-35), por M. A. García Cano, 2024, [Trabajo de especialización, Universidad Nacional Abierta y a Distancia].

Estos datos serán importantes para el procedimiento, por lo tanto para un mejor análisis de los mismos, a continuación se presentarán una serie de histogramas que harán más sencilla la interpretación de los datos recopilados.


Gráficos de variables categoricas



Fuente: Elaboración propia.



Fuente: Elaboración propia.



Fuente: Elaboración propia.

La prueba saber pro se da en un rango de los 0 a 300 puntos, generalmente un puntaje bueno se encuentra en el rango de 145 a 149, y uno sobresaliente entre 165 a 180 puntos


García Cano (2024) sugiere generar una segmentación de niveles,

“Nivel Bajo, Medio Bajo, Nivel Medio, Medio Alto y Nivel Alto, esto me serviría para realizar el análisis clasificatorio en cualquier modelo de algoritmo de machine learning, para luego así poder analizar que estudiantes tendrán un bajo rendimiento y sus posibles causas”

Se segmentan los niveles así:

- Nivel Bajo: 0–60
- Medio Bajo: 60–120
- Nivel Medio: 120–180
- Medio Alto: 180–240
- Nivel Alto: 240–300

Consiguientemente se Genera el siguiente esquema:



Fuente: Elaboración propia.

Visiblemente se ve presente que el nivel académico demostrado en los datos analizados en esta prueba saber se ven mayoritariamente reflejados en resultados de nivel medio cerca a los 70 mil estudiantes.

asd

División de datos en subconjuntos representativos para el entrenamiento

Para subdividir los datos en subconjuntos de entrenamiento y demás se va a hacer uso del principio de train-validation-test set, esto va a consistir en que para entrenar el algoritmo de machine learning se usará un 80% de la información disponible, en este caso optamos por el periodo que comprende desde el 2022-1 hasta el 2023-1 (71725 datos), dejando por fuera el 2023-3, que a su vez servirá como la validación de nuestro algoritmo, fungiendo como un 20% restante (18899 datos), y una vez se haga este proceso, se hará el test con datos del 2021-3 para comprobar si el algoritmo es funcional y que tenga cierto grado de validez. (10) (Baheti, s.f.)

El 2023-2 se eligió para hacer la comprobación debido a que cuentan con mayor confiabilidad al ser los más recientes de nuestro sistema (lo que contribuye a que la información presente tenga mayor validez), y el test se hará con 2021-3 porque aunque sean datos antiguos y en un contexto diferente al de los futuros años, es el más reciente después de los ya tomados, y podría darnos una idea del resultado final de lo efectiva que fue la técnica usada para el manejo de la información. Así mismo el tipo de partición de la información va a corresponder a uno de estratificación, pues vamos a separar los datos por categorías (periodos), es especialmente útil en este contexto debido a que los datos son similares en los mismos periodos (las pruebas son diferentes en cada caso), y hacer una partición aleatoria podría suponer más tiempo de entrenamiento.

Es importante recalcar que el no hacer la división de los datos, y hacer las comprobaciones y el entrenamiento en un mismo dataset podría generar data leakage o también llamado fuga de datos, lo cual afectaría intensamente el modelo predictivo, como la pobre generalización en datos nuevos, toma de decisiones sesgada, perspectivas y hallazgos poco fiables, métricas de rendimiento infladas, desperdicio de recursos, y complicaciones y riesgos legales ([11](#)) (Mucci, 2024)

Patrones y tendencias en los datos

Para identificar patrones y tendencias en los datos del Saber Pro, se siguen estas estrategias:

- **Análisis Exploratorio de Datos (EDA):**
 - Se usaron histogramas y gráficos de distribución para observar la concentración de puntajes por nivel socioeconómico, disponibilidad de recursos (internet, computador, becas, etc.) y región geográfica.
 - Se identificó que la mayoría de los estudiantes se encuentran en un rango medio de desempeño (120–180 puntos), con una concentración mayor hacia los 145–149, considerado un rendimiento promedio.
- **Segmentación por niveles de rendimiento:**
 - Clasificación de estudiantes en cinco niveles: Bajo, Medio Bajo, Medio, Medio Alto y Alto (cada uno con rangos de 60 puntos).
 - Esto permitió correlacionar más fácilmente características como el estrato, nivel educativo de los padres, acceso a tecnologías, etc., con el desempeño académico.
- **Observación de correlaciones:**

- Se observaron correlaciones positivas entre variables como el nivel educativo de los padres, estrato socioeconómico, y acceso a recursos tecnológicos con un mejor rendimiento en Saber Pro.
- Variables como número de horas trabajadas por semana y autopago de matrícula tienden a correlacionar con puntajes más bajos.

Características más relevantes para el modelo

Para identificar las variables más importantes que afectan el desempeño, se aplicaron técnicas estadísticas y de machine learning:

- Medidas descriptivas y análisis de correlación:
 - Variables como FAMI_ESTRATOVIVIENDA, FAMI_TIENEINTERNET, FAMI_TIENECOMPUTADOR, FAMI_EDUCACIONPADRE y FAMI_EDUCACIONMADRE mostraron correlaciones altas con el puntaje Saber Pro.
- Modelos explicativos preliminares:
 - Se utilizó regresión lineal múltiple para medir el impacto individual de cada variable en el puntaje total.
 - Se utilizaron árboles de decisión para identificar combinaciones de variables que afectan significativamente el resultado.
- Feature importance (importancia de características):
 - Algoritmos como Random Forests y XGBoost pueden extraer automáticamente la importancia de cada variable en la predicción del resultado, priorizando características como:
 - Nivel educativo de los padres
 - Estrato socioeconómico

- Si paga con beca o crédito
- Horas trabajadas por semana
- Origen de la institución (pública o privada)

Características que se usarán para entrenar el modelo

Con base en los análisis anteriores, se seleccionaron características relevantes desde los tres ejes:

Variables socioeconómicas seleccionadas:

- FAMI_ESTRATOVIVIENDA
- FAMI_TIENEINTERNET
- FAMI_TIENECOMPUTADOR
- FAMI_EDUCACIONPADRE
- FAMI_EDUCACIONMADRE
- ESTU_PAGOMATRICULABECA
- ESTU_PAGOMATRICULACREDITO
- ESTU_HORASSEMANATRABAJA

Variables personales y académicas complementarias:

- ESTU_GENERO
- EDAD_ESTUDIANTE
- ESTU_PRGM_ACADEMICO
- INST_ORIGEN
- ESTU_SEMESTRECURSA

Variables categóricas para clasificación (si se usa regresión logística o árboles):

- Segmentación del puntaje Saber Pro en niveles de rendimiento.
- Región o municipio de residencia (ESTU_DEPTO_RESIDE, ESTU_MCPIO_RESIDE), si se busca análisis geográfico.

Resultados

Conclusiones

Se

Bibliografía

- (1) García, M. (2024). *Técnicas de Machine Learning para la predicción del rendimiento académico en las pruebas Saber Pro en Colombia*.
<https://repository.unad.edu.co/bitstream/handle/10596/62951/mgarcia.pdf?sequence=1&isAllowed=y>
- (2) Paterson M. (2024). *Gender, socioeconomic status, and numeracy test scores*.
<https://www.sciencedirect.com/science/article/pii/S0167268124003652?via%3Dihub>
- (3) Reuters Institute. (2023). *Resumen ejecutivo y hallazgos clave del informe de 2023. Reuters Institute for the Study of Journalism*.
<https://reutersinstitute.politics.ox.ac.uk/es/digital-news-report/2023/dnr-resumen-ejecutivo>
- (4) McKinsey & Company. (2022). *El estado de la IA en 2022 y el balance de media década*.
<https://www.mckinsey.com/featured-insights/destacados/el-estado-de-la-ia-en-2022-y-el-balance-de-media-decada/es>
- (5) Ministerio de Telecomunicaciones y de la Sociedad de la Información. (2025). *Política Pública para la Transformación Digital del Ecuador 2025-2030*.
- (6) Martínez Alba, M. G., García Munguía, C. A., Meráz Jiménez, A. de J., Mata Zamores, S., Olvera González, J. E., & García Munguía, A. M. (2025). *La gestión del conocimiento y su relación con el empoderamiento de las mujeres universitarias*. *RIDE Revista Iberoamericana Para La Investigación Y El Desarrollo Educativo*, 15(30).
- (7) Panda, R. M., & Daya Sagar, B. S. (2022). Decision tree [Árbol de decisión]. En B. S. Daya Sagar, Q. Cheng, J. McKinley, & F. Agterberg (Eds.), *Encyclopedia of*

Mathematical Geosciences (pp. 1–7). Springer.

https://doi.org/10.1007/978-3-030-26050-7_81-2

- (8) Starbuck, C. (2023). *Logistic regression*. En *The Fundamentals of People Analytics* (pp. 223–238). Springer.
https://doi.org/10.1007/978-3-031-28674-2_12SpringerLink
- (9) ICFES. (2025). *Acerca del examen Saber Pro*.
<https://www.icfes.gov.co/evaluaciones-icfes/acerca-del-examen-saber-pro/>
- (10) Baheti, P. (s.f.). *What's the optimal machine learning data split ratio and how to achieve it?*. <https://www.v7labs.com/blog/train-validation-test-set>
- (11) Mucci, T. (2024). *What is data leakage in machine learning?*.
<https://www.ibm.com/think/topics/data-leakage-machine-learning>
- García Cano, M. A. (2024). *Técnicas de Machine Learning para la predicción del rendimiento académico en las pruebas Saber Pro en Colombia* [Trabajo de especialización, Universidad Nacional Abierta y a Distancia].